


## I. 요약

**문제.** 생성 영상을 통한 VLA 성능 테스트가 유용하지만, 물리적으로 일관적이지 않은 인공물이 발생하므로 실물 로봇 실험과의 차이가 발생한다.

**질문.** 참조할 정답 영상 없이 불완전한 생성 영상을 걸러냄으로써 실물 평가와 보다 유사한 테스트 결과를 얻을 수 있는가?

**동기.** 생성 영상의 점수를 평가하여 물리적으로 일관된 영상과 그렇지 않은 영상의 특성을 서로 다른 점수로 나타낼 수 있다.




↑ OpenVLA의 Task Success Rate(좌: 생성 영상 / 우: 실물 실험)

## II. 핵심 아이디어

영상의 물리적 일관성 계산

- 여러 영상에서 영상 필터링: 같은 작업에 대한 생성 영상 비교 → 상대 평가
- 하나의 영상에서 가장 문제가 되는 프레임 확인: 인접 프레임 및 픽셀 비교 → 절대 평가

## III. 방법론



### 1. 상대 평가

- 동일 상황에 대해 여러 비디오를 WorldGym으로 생성 → 각 영상을 World Score의 평가 지표로 계산
  - 3D Consistency: DROID-SLAM 사용
  - Photometric Consistency: SEA-RAFT 사용
  - Subjective Results: CLIP-Aesthetic 사용
- 3개 점수의 분산을 비교 → 생성 영상에서 이상치가 더 많은 3D/광학 일관성을 영상의 평가 점수로 활용
- Shannon Entropy로 3D/광학 일관성의 정보량을 평가

$$H(p) = - \sum_{i=1}^n p(x_i) \log p(x_i)$$

- stable softmax로 각 점수에 곱할 가중치를 계산

$$w_k = \frac{\exp(-H_k)}{\sum_j \exp(-H_j)}$$

- 가중합weighted sum으로 상대적 이상치 점수를 산출

$$S_r = w_3 \cdot \hat{s}_3 + w_p \cdot \hat{s}_p$$

## III. 방법론

### 2. 절대 평가

- 시점 탐지: DROID-SLAM의 factor graph에서 residual을 비교하여 재투영 오차가 가장 큰 프레임 확인



$$j_t = |e_t - e_{t-1}|, \quad t^* = \arg \max_t (j_t)$$

- 위치 탐지: 각 edge에서 L2 Norm으로 픽셀별 잔차를 계산, 오차 값을 heatmap으로 시각화

$$M_i(u, v) = \|\delta_i(u, v)\|_2$$

## IV. 실험 결과

### 1. 상대 평가



- 상대적 점수가 낮은 생성 영상은 실제 작업 영상과 더 유사하다.
- 생성 영상 중 비교적 실제와 가까운 영상을 사람의 검수나 정답 데이터 없이 분류할 수 있다.

### 2. 절대 평가



- 이전 프레임과의 오차가 가장 큰 프레임에서 눈에 보이는 오류도 크다.
- 픽셀별 오차 값으로 해당 프레임에서 가장 신뢰할 수 없는 영역을 heatmap으로 시각화할 수 있다.



## V. 결론

- 기하학/광학 일관성을 수치화하여 여러 영상의 물리적 일관성을 상대 평가할 수 있다. 각 프레임의 잔차를 계산하여 영상 안에서 물리적으로 부자연스러운 객체가 발생하는 지점을 절대 평가하여 시각화할 수 있다.
- OpenVLA와 WorldGym 위주로 실험했다. 다른 VLA 모델 및 다양한 월드 모델의 일반화를 위해 추가 실험이 필요하다.
- 제안한 절대 평가 방법은 Grok, Sora 등 생성 영상에서 정확한 결과를 얻지 못할 수 있으며, noise가 심한 경우 0점이 발생하여 계산이 실패하는 경우도 있으므로 계산 방법 개선이 필요하다.