

시청각 통합 AI를 통한 사람-로봇 간 상호작용 모델 탐색

인공지능학과 2023012533 오윤

연구 동기와 탐구 방향

로봇과 인간이 소통하기 위한 기술에 관심이 있어서 인공지능 전공을 선택한 만큼, 이 에세이에서는 전공분야에서 4차 산업혁명 기술을 활용한 프로젝트 수행 후 보고서를 제출하기로 했습니다. 수행한 프로젝트는 음성과 시각 정보를 통합해 '사람이 말로 지시하면 로봇이 그 물건의 위치를 인지하는' 인공지능 파이프라인 제작입니다.

'시각 인공지능'의 대상이 되는 '이미지'와 '청각 인공지능'의 대상이 되는 '소리'는 그 물리적인 특성이 다른 만큼, 입력 데이터의 형태도 다릅니다.

이미지는 모양과 색을 가집니다. 물리적으로는 빛이 어떻게 공간에 퍼져 있는지 나타내는 '공간적 정보'와, 빛의 강도와 파장을 나타내는 '스펙트럼 정보'로 구성됩니다.¹⁾ 공간 정보는 가로와 세로로 이루어진 2차원 배열이며, 스펙트럼 정보는 각 위치에서의 밝기나 색상을 나타내는 1차원 벡터입니다. 디지털 이미지에서는 이를 height, width, channel 형태로 표현하며, RGB(3채널) 이미지가 그 대표적인 예시로, 이미지 데이터는 보통 3차원 배열로 다룹니다.²⁾

소리는 공기 입자의 진동으로, 시간에 따라 진폭(amplitude)이 변하는 파형입니다. 즉, 시간(t)에 따른 함수 $f(t)$ 로 표현되며 1차원 시계열 데이터입니다. 하지만 소리의 주파수 성분을 시간에 따라 분석하기 위해 푸리에 변환을 적용하면, 시간과 주파수의 관계를 나타내는 2차원 행렬인 스펙트로그램(spectrogram)을 얻을 수 있습니다.³⁾ 이미지에서 3번째 차원이 없으면 흑백 이미지로 볼 수 있으므로, 스펙트로그램을 통해 이미지 처리 기술로 소리를 처리하는 것이 가능합니다.

하지만 서로 다른 두 소리가 같은 주파수를 가지더라도 시간이 다르다면 전혀 다른 소리로 들리는데, 소리를 스펙트로그램으로 변환하여 이미지처럼 처리할 때 시간적 연속성은 고려하지 못하게 됩니다. 그렇기에 이미지를 잘 처리하는 모델도 소리는 잘 처리할 수 없고, 반대로 소리를 잘 처리하는 모델도 이미지는 잘 처리하기 어렵습니다.

이를 해결하기 위한 선행 연구가 없지 않습니다. 구글의 딥마인드에서 개발한 Perceiver IO, 독일 튀빙겐대학교에서 연구한 AudioCLIP 같은 모델이 있습니다. 하지만 한꺼번에 많은 연산을 해야 하기 때문에 실시간성에 한계가 있었고, 이 글을 작성하는 시점 기준으로 4년이 지나도록 더 발전된 최신 모델이 발표되지 않았습니다. 2015년 발표된 객체인식 모델 YOLO가 인기에 힘입어 거의 매년 새로운 모델을 발표하여 현재 12번째 버전까지 나온 것과 비교됩니다.⁴⁾ 다양한 VLM 모델이 연구되고 있지만 '음성' 입력을 포함하는 경우는 눈에 띄지 않습니다.

1) Li, Ze-Lian and Mark S. Drew, *Fundamentals of Multimedia* (Upper Saddle River, NJ: Pearson/Prentice Hall, 2004), 82.

2) Ibid., 100.

3) Ibid., 126.

4) Tian et al. (2025). "YOLOv12: Attention-Centric Real-Time Object Detectors" <https://doi.org/10.48550/arXiv.2502.12524>

2023년 11월부터 실외이동로봇의 보도 통행을 포함한 개정 지능형로봇법이 시행되었고, 이제 식당에서, 백화점에서, 카페에서, 길거리에서 로봇을 보는 것이 낯설지 않아졌습니다. 비록 로봇과 사람의 소통은 부족하지만, 로봇과 함께 사는 사회는 미래가 아닌 현재입니다.

한편 아직은 평범한 인간의 소통능력도 최고 수준(State of the art; SOTA)의 인공지능보다 사람과 소통하기에 더 낫습니다. 음성 기반 인공지능 기술이 점점 보편화되고 있다 하더라도 실제 사용 경험을 떠올려보면 여전히 어색하거나 민망한 순간이 많습니다. 예를 들어 Siri에게 말을 걸었을 때 잘 못 알아들었다며 사용자가 했던 말을 반복해야 하거나, ChatGPT의 경우에도 의도한 바와 다르게 멋대로 해석하는 경우가 많습니다. 그런가 하면 원어민과의 대화를 연습할 수 있게 해주겠다는 듀오링고Duolingo를 비롯한 외국어 학습 어플리케이션 또한 음성 대화가 기대만큼 자연스럽지 못합니다. 텍스트로는 놀라운 성능을 보여주는 인공지능이지만, 실제 상호작용에서는 인간처럼 자연스럽게 유연하게 반응하지 못합니다.

현재 음성 인식은 발화를 텍스트로 옮기는데, 이 과정은 필연적으로 구어가 가지는 다양한 정보를 누락하게 됩니다. 단순 발음 인식 또한 아직 완벽하지 않으며, 인간은 부정확한 발음이나 어휘도 맥락을 통해 인지할 수 있고 말의 내용만큼 톤과 맥락도 중요하게 받아들이는 데 비해, 기계는 상대가 흥분하거나 긴장했는지, 무례하거나 정중한지 등을 쉽게 알아차리지 못합니다. 게다가 실제 인간이 소통할 때는 시청각 정보가 함께 사용되기 때문에 한 가지 기술만으로 부족하기도 합니다. 로봇이 인간과 소통하려면 각각의 감각을 인지하는 모델이 개선되어야 하고, 여러 감각의 통합도 필수입니다.

이런 문제의식으로 출발했지만, 몇 개월 만에 새로운 모델을 개발하기는 쉽지 않습니다. 이 프로젝트에서는 새로운 것을 개발하기보다는 기존 연구를 이해하고, 그 이해를 바탕으로 기존 모델을 결합해 보고자 합니다. 먼저 2021년에 발표된 Perceiver IO와 AudioCLIP의 논문을 통해 멀티모달 모델의 구조를 알아보고, 파이프라인을 구현해 보고자 합니다. 구현 이전에 인공지능 모델의 성능을 어떤 기준으로 판단하는지도 알아보겠습니다.

Perceiver IO 및 AudioCLIP 구조 분석

먼저 Perceiver IO는 입력(Encoding)-처리(Processing)-출력(Decoding) 구조로 이루어져 있습니다.

입력 단계에서는, 다양한 형태의 입력(텍스트, 이미지, 오디오 등)을 동일한 방식으로 처리하기 위해 입력 배열을 고정된 크기의 잠재 배열(latent array)로 압축합니다. 이 과정에서 트랜스포머의 self-attention과 유사한 cross-attention이 사용되고, 어떤 형태의 데이터든지 처리할 수 있습니다. 어텐션은 입력 중 중요한 정보에 집중하는 구조이며, 서로 다른 입력 간 관계를 학습할 때는 cross-attention을 사용합니다. 중요한 정보 여부는 벡터 간 유사도(내적inner product)를 계산 후 가중합을 만들어서 판단합니다.⁵⁾

이후 잠재 배열이 여러 층의 블록을 거치며 처리됩니다. 잠재 공간은 입력의 공간적/시계열 구조를 유지하지 않으며, 잠재 배열은 입력이 아무리 길어도 크기가 고정되어 계산에 효율적입니다. 다만 데이터를 압축하는 과정에서 너무 작은 값의 잠재배열로 만든다면 정보 손실이 커지므로, 학습 시 latent 개수와 차원 수를 적절히 조절해야 합니다.

최종 출력은 잠재 배열로부터 얻어낸 질문(query)을 사용합니다. 출력 쿼리는 원하는 출력

5) Vaswani et al. (2017). "Attention is all you need." <https://doi.org/10.48550/arXiv.1706.03762>

의 종류나 위치에 대한 정보를 포함하며, 이를 통해 잠재 표현으로부터 특정 작업에 적합한 (task-specific) 출력을 추출합니다.⁶⁾

결과적으로 Perceiver IO는 트랜스포머 구조와 유사하지만, 더 유연합니다.

AudioCLIP의 경우, OpenAI에서 발표한 텍스트-이미지 인식 모델 CLIP⁷⁾을 확장한 것입니다. AudioCLIP은 텍스트/이미지/오디오에 해당하는 3가지 입력값에 대해 추론할 수 있고, 공통 임베딩 공간(shared embedding space)에서 서로 다른 데이터가 갖는 의미적 유사성을 학습합니다.⁸⁾

두 모델의 차이점을 단순히 말하자면, Perceiver IO는 새로운 구조를 설계했다면, AudioCLIP은 기존 모델에 모달을 하나 더 추가한 것이라고 볼 수 있습니다. 두 모델의 공통 점은 사전 학습한 적 없는 작업이나 입력 형태에 대해서도 zero-shot(전혀 학습 없이) 또는 few-shot(몇 개의 예제만 제공받고) 추론이 가능하다는 점입니다. 하지만 Perceiver IO는 출력을 위해 쿼리 설계를 작업에 맞게 할 필요가 있는데 이 작업이 까다롭고, AudioCLIP 또한 실제 결과 활용을 위해서는 후처리가 필요합니다.

인공지능 모델의 성능 판단 기준

모델의 성능을 판단하는 기준으로는 정확도(accuracy), 정밀도(precision), 재현율(recall), F1 score가 있습니다. 정확도는 전체 중 정답을 맞힌 비율이고, 정밀도는 '맞다고 한 것들 중에 진짜 맞은 비율', 재현율은 '실제로 맞는 것 중에 얼마나 많이 찾아냈는지'를 의미합니다. F1 score는 정밀도와 재현율의 조화 평균으로, 두 성능을 균형 있게 보고 싶을 때 사용합니다.

비정형 데이터에서는 오디오의 경우 top-k 정확도, 이미지의 경우 IoU(Intersection over Union)을 활용합니다. top-k 정확도는 정답이 상위 k개 예측 안에 포함됐는지 확인하는 방식이고, IoU는 예측한 객체 영역과 실제 객체 영역의 겹치는 정도, 즉 (교집합)/(합집합)을 의미합니다. 이에 더해 Zero-shot 모델에서는 예측 결과와 실제 정답 사이의 의미 유사도 평가도 중요합니다.

Perceiver IO 논문에서는 다양한 입력 모달리티(이미지, 포인트 클라우드, 오디오 등)를 적용하여 모델을 학습시키고, 각각의 작업에 맞는 평가 지표를 활용했고, 하나의 입력 모달리티에 대응하는 기존 모델들에 근접하거나 능가하는 성능을 보였습니다.

AudioCLIP 논문에서는 텍스트-오디오-이미지 삼중 모달리티 간의 임베딩 정렬 성능을 중심으로 평가했고, 다양한 모달리티에 대해 동시에 의미 기반 정렬을 수행할 수 있다는 점에서 확장성과 응용 가능성이 뛰어나다고 볼 수 있습니다.

Perceiver IO와 AudioCLIP은 모두 정량적인 정확도, 분류 성능, 유사도 기반 지표를 통해 모델 성능을 평가했고, 사용자 경험과 같은 정성적 지표는 고려하지 않았습니다. 하지만 해당 모델을 실제 사람과의 상호작용에 적용할 경우, 정확도뿐 아니라 사용자의 체감 만족도 등 정성적 요소 또한 중요한 평가 기준으로 고려할 필요가 있습니다.

6) Jaegle et al. (2021). "Perceiver IO: A General Architecture for Structured Inputs & Outputs" <https://doi.org/10.48550/arXiv.2107.14795>

7) Radford et al. (2021). "Learning Transferable Visual Models From Natural Language Supervision" <https://doi.org/10.48550/arXiv.2103.00020>

8) Guzhov et al. (2021). "AudioCLIP: Extending CLIP to Image, Text and Audio" <https://doi.org/10.48550/arXiv.2106.13043>

Whisper-Grounding DINO 기반 멀티모달 파이프라인 구축

Perceiver IO와 AudioCLIP은 새로운 모델 제안으로서 의미있었으나, 실제로 활용하기 어려운 면이 있어 비교적 고성능이 아닌 하드웨어 환경에서도 학습 및 추론이 가능한 파이프라인을 구축해 보는 소규모 프로젝트를 진행했습니다. 이를 위해 선택한 것은 음성을 텍스트로 변환하는 Whisper⁹⁾ 모델과, 텍스트 기반으로 객체를 인식하는 Grounding DINO입니다.

Whisper를 선택한 이유는 최근 발표된 음성 인식 모델 성능 비교 기사문에서 가장 성능이 좋은 음성 인식 모델이었기 때문입니다.¹⁰⁾ 한편 로봇이 물건을 집기 위해서는 객체가 위치한 정확한 좌표를 알아야 하고, 이를 위해 바운딩 박스를 표시하는 모델이 필요합니다. 객체인식 모델로 많이 활용되는 YOLO는 사전에 학습된 객체만 인식하는 One-shot 모델인 반면, Grounding DINO의 경우 텍스트를 통해 학습한 적 없는 이미지도 인식하는 Zero-shot 모델이라는 장점이 있어 Grounding DINO를 선택했습니다.¹¹⁾

두 모델의 발표 시점은 멀티모달을 하나의 모델로 해결하고자 했던 2021년의 시도(Perceiver IO, AudioCLIP) 이후이므로, 조금은 가벼운 두 개의 모델을 연결하여 사용하는 것이 하나의 거대한 모델을 사용하는 것에 비해 장점이 있을지도 실험해 보고 싶었습니다.

실험은 학교에서 RTX 2080 GPU가 탑재된 서버 환경을 대여하여 진행했고, PyTorch로 모델을 불러와서 추론해 보았습니다. 경량 모델 파이프라인 구축이 목적이었으므로, Whisper는 base, Grounding DINO도 Swin-T로 가벼운 모델을 사용했습니다. 실제라면 실시간 음성을 인식하는 것도 중요할 텐데, 실험의 간소화를 위해 mp3 음성 파일을 사용했습니다.

Grounding DINO는 한국어에 대해서는 객체 인식할 수 없기 때문에, Whisper가 한국어 음성을 텍스트로 변환한 후 google translator 라이브러리를 통해 영어로 변환한 텍스트를 저장했습니다. 이후 해당 파일을 Grounding DINO에 입력값으로 넘겨 텍스트에 상응하는 객체를 인식하게 했습니다.

실험 결과 및 향후 연구 방향

기존에 존재하는 모델을 연결하는 파이프라인 구성이기 때문에 실험이 아주 간단할 것으로 예상했지만, 진행하면서 가장 골치가 아팠던 부분은 GPU 칩과 다양한 Python 라이브러리 설치 시 CUDA 버전과 호환되게 설치하는 것이었습니다.

CUDA는 NVIDIA가 만든 GPU를 위한 소프트웨어 플랫폼으로, CUDA 버전은 GPU 칩의 물리적인 아키텍처에 맞춰서 개발됩니다. 대여한 PC에 장착된 GPU 칩은 NVIDIA GeForce RTX 2080 Ti였는데, 12.4 버전까지의 CUDA를 지원할 수 있었습니다.

Grounding DINO는 OpenAI에 비하면 소규모 중국 팀에서 개발한 모델로, CUDA 11.8 버전을 기준으로 개발되었고 더 높은 버전에서는 호환이 잘 되지 않았습니다. 하지만 CUDA 11.8 버전을 설치하면 다른 라이브러리와 충돌이 있어서 12.1 버전으로 설치했고, Grounding DINO는 따로 설치했는데도 라이브러리 하나를 추가할 때마다 말썹이었습니다.

9) Radford et al. (2022). "Robust Speech Recognition via Large-Scale Weak Supervision" <https://doi.org/10.48550/arXiv.2212.04356>

10) Christopher F., Nish Tahir (2024, November 20). We Tested 10 Speech-to-Text Models. <https://www.willowtreeapps.com/craft/10-speech-to-text-models-tested>

11) Liu et al. (2024). "Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection" <https://doi.org/10.48550/arXiv.2303.05499>

그래서 가상환경을 2개 만들기로 했습니다. 먼저 Whisper와 Google Translator를 하나의 가상환경에 설치하고, Grounding DINO는 로컬에 따로 설치한 후 관련된 라이브러리를 별개의 가상환경에 설치했습니다. 전체 파이프라인 실행은 Python의 subprocess 모듈을 사용했습니다. 먼저 Whisper가 설치된 가상환경을 활성화하여 한국어 음성에 대한 영문 텍스트 파일을 생성한 후, 다시 Grounding DINO가 설치된 가상환경을 활성화하여 텍스트에 해당하는 객체를 이미지에서 찾아서 표시하게 했습니다.

사용한 음성은 "왼쪽에 있는 캔"이라는 내용이었고, 사진에는 캔, 해바라기꽃, 튤립이 담긴 유리병, 고양이가 있었습니다. 아주 간단한 것이지만 실행 시작 시점부터 종료 시점까지 소요된 시간은 15초였습니다. GPU 2080에서 실행이 가능하다는 것이 장점이겠지만, 속도를 높이려면 모델 튜닝을 통한 경량화가 더 필요할 것입니다.

사실 이 프로젝트에서 새로운 모델 개발이나 Visual Transformer 같은 거대 LLM 활용 없이 기존 모델을 연결하는 구성에 그친 가장 큰 이유는 현재 가용한 서버 환경에 맞춘 것입니다. 한국어 텍스트를 통해 객체 인식을 하는 모델을 사용하려고 알아보니 NC Soft의 Varco Vision이 거의 유일하게 공개되어 있는데, 기업의 실험 환경은 NVIDIA A100이었고¹²⁾ 24GB VRAM 이상 GPU가 있어야 원활하게 활용 가능할 것으로 보입니다. 결국은 어떤 칩을 사용할 수 있는지가 개발할 수 있는 모델의 수준이나 개발된 모델 활용을 제약하게 됩니다.

국내에서는 GPU가 부족해서 게이밍 PC의 칩으로 모델링을 해야 하는 연구환경이 많고, 클라우드 GPU, Colab, Hugging Face Spaces 등 대안 실험 환경이 제시되고 있지만 실제로 활용해 보려고 하면 예기치 못하게 연결이 끊어져 취미 활동으로 간단한 확인을 하는 게 아니라면 적절하지 않습니다. 또한 Physical AI를 구현하기 위해 로봇이든 차량이든 GPU를 장착하면 비용도 많이 들고 부피도 커져야 해서 현실적이지 않습니다. 결국 아주 작은 크기로도 추론을 잘할 수 있어서 로봇에 장착하기에도 무리 없는 칩이 개발되거나, 또는 훨씬 적은 연산으로도 추론을 할 수 있는 경량화된 모델이 개발되어야 할 것입니다.

12) Ju et al. (2024). "VARCO-VISION: Expanding Frontiers in Korean Vision-Language Models" <https://arxiv.org/pdf/2411.19103>